UNIVERSIDADE DE SÃO PAULO

FACULDADE DE MEDICINA DE RIBEIRÃO PRETO

PÓS-GRADUAÇÃO EM REABILITAÇÃO E DESEMPENHO FUNCIONAL

LABORATÓRIO DE BIOMECÂNICA E CONTROLE MOTOR

Projeto de Mestrado

Modelos de *Deep Learning* para Rastreamento de Jogadores e Calibração de Câmeras de Drones no Futebol

Candidato: Lennin Abrão Sousa Santos

Orientador: Prof. Dr. Paulo Roberto Pereira Santiago

Ribeirão Preto - Brasil
Janeiro - 2025

Sumário

Resumo **3**

Abstract **3**

1 Projeto de Pesquisa **4**
1.1 Introdução 4
1.2 Justificativa 5
1.3 Objetivos 6
1.3.1 Objetivos Específicos 6
1.3.2 Objetivos Específicos 6
1.4 Materiais e Métodos 6
1.4.1 Considerações Éticas 6
1.4.2 Coleta de Dados 6
1.4.3 Rotulação e Pré-processamento 7
1.4.4 Desenvolvimento e Treinamento dos Modelos 8
1.4.5 Validação 8
1.4.6 Integração com a Plataforma 8
1.4.7 Compartilhamento e Reprodutibilidade 8
1.5 Resultados Esperados 8
1.6 Cronograma 9

Resumo

Este projeto visa desenvolver e disponibilizar modelos de *deep learning* para análise de vídeos de futebol a partir de imagens aéreas capturadas por drones em perspectiva superior. Inspirados pelo SoccerNet Camera Calibration Challenge, a presente proposta visa treinar e/ou retreinar redes neurais que realizem rastreamento de jogadores e calibração de câmeras. O foco principal é o rastreamento de jogadores em categorias de base, permitindo a obtenção de dados precisos sobre deslocamentos e posicionamentos. Além disso, propõe-se a detecção de linhas e pontos-chave do campo, viabilizando a homografia para então calibrar câmeras e realizar a reconstrução geométrica do cenário esportivo. A estratégia inclui o uso de GPUs (Unidade de Processamento Gráfico) de alto desempenho para treinar modelos robustos de *deep learning*, além de técnicas de ajuste de dados que compensam anotações imperfeitas. Utilizar redes neurais profundas é essencial para extrair informações valiosas de vídeos esportivos, mas muitas vezes inviável para profissionais ou pesquisadores da área de Educação Física e Esporte, devido à alta complexidade técnica e aos custos associados. Assim, disponibilizar essas ferramentas de forma simplificada e acessível é fundamental para promover novos estudos e incentivar avanços tecnológicos e científicos na área.

Palavras-chave: Inteligência Artificial no Esporte, Tecnologia no Esporte, Processamento de Imagens, Redes Neurais Convolucionais, Cinemática, Drones no Esporte.

Abstract

This project aims to develop and provide *deep learning* models for analyzing soccer videos captured by drones from an overhead perspective. Inspired by the SoccerNet Camera Calibration Challenge, this proposal seeks to train and/or retrain neural networks capable of player tracking and camera calibration. The primary focus is on tracking players in youth categories, enabling the precise acquisition of data on movements and positioning. Additionally, the project proposes detecting field lines and keypoints, facilitating homography for camera calibration and geometric reconstruction of the sports environment. The strategy involves using high-performance GPUs (Graphics Processing Units) to train robust *deep learning* models, as well as data adjustment techniques to compensate for imperfect annotations. Employing deep neural networks is essential for extracting valuable insights from sports videos, yet it is often unfeasible for professionals or researchers in the fields of Physical Education and Sports due to the high technical complexity and associated costs. Thus, providing these tools in a simplified and accessible manner is crucial for fostering new studies and driving technological and scientific advancements in the field.

Keywords: Artificial Intelligence in Sports, Sport Technology, Image Processing, Convolutional Neural Networks, Kinematics, Drones in Sports.

1 Projeto de Pesquisa

1.1 Introdução

A análise de desempenho no futebol tem evoluído significativamente com a incorporação de tecnologias avançadas da computação, como a visão computacional e *deep learning* [1, 2, 3]. Essas inovações permitem o rastreamento em menor tempo de jogadores de futebol em campo, além da calibração de câmeras, otimizando e facilitando pesquisas e aplicações práticas neste esporte.

No contexto acadêmico, este projeto de pesquisa se insere de maneira ideal em um programa de Mestrado, pois propõe o desenvolvimento e aplicação de modelos avançados de *deep learning* para um problema concreto dentro da área de Educação Física e Esporte. O estudo combina técnicas treinamento/retreinamento para resolver desafios fundamentais relacionados à análise de movimento e desempenho de jogadores, um tema que exige um aprofundamento técnico aliado a aplicações práticas no campo esportivo.

Com o avanço exponencial da Computação com IA nos últimos anos, soluções baseadas em redes neurais profundas vêm transformando diversas áreas do conhecimento, incluindo o esporte. Tecnologias emergentes, como *markerless motion capture* [4] (rastreamento sem marcadores físicos) e aprendizado de máquina aplicado à biomecânica, possibilitam a análise de desempenho com maior precisão e acessibilidade. Este projeto busca contribuir para essa revolução tecnológica ao desenvolver ferramentas capazes de extrair e interpretar dados de movimento a partir de imagens capturadas por drones, algo ainda pouco explorado no Brasil.

Além disso, a Educação Física e o Esporte vêm se beneficiando cada vez mais de abordagens computacionais, permitindo análises biomecânicas mais precisas, treinamento individualizado com base em dados e tomadas de decisão fundamentadas em estatísticas avançadas. A crescente demanda por ferramentas automatizadas na análise esportiva reforça a relevância deste estudo, que não apenas avança o estado da arte no rastreamento de jogadores, mas também propõe soluções acessíveis para clubes, treinadores e pesquisadores.

O impacto acadêmico e prático do projeto é amplificado pelo seu alinhamento com um programa de Mestrado, pois envolve um equilíbrio entre pesquisa aplicada e desenvolvimento tecnológico. O estudo fornecerá contribuições originais à literatura científica, promovendo a interdisciplinaridade entre computação e ciências do esporte, além de estabelecer novas possibilidades para futuras investigações na área. Dessa forma, este projeto representa uma oportunidade única de explorar o potencial da Inteligência Artificial no esporte, ao mesmo tempo que gera conhecimento útil para a academia e o setor esportivo.

Relevância Sociopedagógica e Foco nas Categorias de Base: Embora grande parte das tecnologias de análise esportiva seja direcionada a equipes de alto rendimento, há uma lacuna considerável no desenvolvimento de ferramentas acessíveis para crianças e adolescentes que praticam futebol em categorias de base. Sob uma perspectiva socioeducativa, o uso de drones e algoritmos de *deep learning* em faixas etárias mais jovens pode fornecer informações valiosas sobre desenvolvimento motor, tática e aspectos cognitivos do jogo, contribuindo para um acompanhamento formativo mais justo e inclusivo. Além disso, os dados obtidos podem ser utilizados não apenas para aperfeiçoar o desempenho esportivo, mas também para embasar tomadas de decisão relacionadas à saúde, à prevenção de lesões e ao planejamento pedagógico dentro do contexto do futebol de formação. Iniciativas como essa também ajudam a valorizar crianças e jovens ao demonstrar que eles não são apenas praticantes do esporte, mas podem, no futuro, se tornar pesquisadores e inovadores, contribuindo ativamente para o universo de pesquisa e tecnologia e reforçando seu sentimento de pertencimento, servindo como inspiração e exemplo para novas gerações.

Limitações no Uso de Drones e Justificativa para Categorias Jovens: No futebol profissional, o uso de drones em partidas oficiais enfrenta restrições regulatórias e logísticas, dificultando a implementação de análises em tempo real no alto nível. Em contrapartida, a pesquisa em jogos simulados ou nas categorias de base não sofrem tantas limitações e permite uma aplicação mais livre de tecnologias experimentais, resultando em dados mais confiáveis para fins acadêmicos. Dessa forma, o presente projeto centra seus esforços na coleta de dados em ambientes controlados de categorias jovens, aproveitando a flexibilidade e a acessibilidade que esse contexto oferece, para aprimorar métodos de rastreamento, calibração de câmeras e análise de desempenho de forma segura e ajustada às necessidades desse público.

No entanto, embora estas tecnologias sejam promissoras, seu desenvolvimento e aplicação frequentemente requerem conhecimentos especializados em ciência da computação, além de recursos computacionais avançados. Profissionais e pesquisadores da área de Educação Física e Esporte enfrentam dificuldades significativas para implementar soluções de visão computacional e *deep learning*, devido à alta complexidade técnica e aos custos envolvidos.

Figueiredo e Leite (2000) exploraram a calibração dinâmica de câmeras para rastrear jogadores durante partidas, destacando a importância de dados acurados para análises biomecânicas e táticas [5]. Cioppa et al. (2021) abordaram a calibração de câmeras de TV para a localização de jogadores no SoccerNet-v2, contribuindo para a detecção de eventos em vídeos de transmissões esportivas [6]. Fernandes e Kenwright (2022) demonstraram o uso de dados sintéticos para treinar algoritmos de *machine learning* na identificação de características do futebol, superando limitações de dados reais [7].

Estudos recentes têm destacado a relevância de métodos computacionais emergentes para áreas correlatas. Como exemplo, é possível destacar os estudos de Palucci Vieira et al. (2019),

ao revisarem o desempenho em partidas de jovens jogadores, ressaltaram a necessidade de ferramentas que capturem e analisem deslocamentos de forma precisa, especialmente em contextos dinâmicos como o futebol [8]. Monteiro et al. (2024) demonstraram como técnicas de instrução por vídeo e medidas cinemáticas com visão computacional podem beneficiar o desempenho de salto de goleiros de futebol, o que demonstra o potencial de sistemas computacionais mais acessíveis para treinar habilidades específicas [9]. Bedo et al. (2020), ao propor um modelo computacional para análise de movimentos e a estimativa da ação musculoesquelética, estimaram forças tibiofemorais. Estes e outros estudos destacaram o valor de integrações com dados biomecânicos acurados [10].

Iniciativas interdisciplinares na ciência do esporte e computação são requeridas no contexto atual de pesquisa, gerando chamadas especiais em livros e revistas científicas. Exemplos incluem o capítulo de livro de Claudino et al. (2022) sobre inteligência artificial na medicina esportiva, que reforça a importância de adaptar soluções computacionais avançadas a cenários práticos e acessíveis, promovendo inovação em saúde e desempenho esportivo [11]. A relevância desse tema também é destacada por chamadas especiais recentes, como as publicadas no *Journal of Sports Sciences* por Bini et al. (2024), que discute a aplicação de técnicas de aprendizado de máquina para *Markerless* no esporte [4], e a chamada aberta para contribuições sobre Artificial Intelligence in Sport. Essas iniciativas evidenciam a relevância e o impacto global do uso de inteligência artificial no esporte, destacando a necessidade de o Brasil avançar nesses aspectos para não ficar inerte em relação ao que o mundo tem desenvolvido.

Assim, a presente proposta visa não apenas desenvolver modelos de *deep learning* para rastreamento de jogadores e calibração de câmeras de vídeo de drones no contexto do futebol, mas também disponibilizá-los em uma plataforma acessível, como exemplo de plataforma multimodais. Ao integrar os modelos treinados ao *vailá: Versatile Anarcho Integrated Liberation Ánalysis in Multimodal Toolbox* [12], buscamos facilitar o acesso ao uso de *deep learning*, permitindo que profissionais da área esportiva possam utilizá-las sem a necessidade de conhecimentos técnicos avançados em computação. A proposta inspira-se em iniciativas como o projeto DeepLabCut, que provou ser uma ferramenta computacional para estimativa de pose animal, rastreamento e análise multimodal, além de estudos como os artigos do grupo Nature [13, 14], que destacam a importância de ferramentas acessíveis para fomentar a colaboração interdisciplinar. Tais ferramentas têm mostrado grande potencial em diferentes domínios científicos, integrando-se perfeitamente às necessidades do esporte moderno.

Por fim, essa iniciativa busca promover a modernização das práticas analíticas no esporte, fomentar colaborações interdisciplinares entre ciência do esporte e ciência da computação, e beneficiar diretamente pesquisadores que trabalham com análise biomecânica, treinamento de habilidades específicas e desempenho esportivo.

1.2 Justificativa

O projeto representa uma oportunidade significativa para avançar na integração de tecnologias emergentes, como drones, *deep learning* e visão computacional, à análise esportiva, com foco no contexto do futebol. A proposta vai além do aprimoramento de métodos existentes, buscando transformar o campo da análise de desempenho ao introduzir soluções inovadoras que combinem acessibilidade e eficiência.

Do ponto de vista científico, o projeto visa expandir o conhecimento sobre o uso de redes neurais e análise de imagens aéreas aplicadas ao esporte. Ao explorar novas arquiteturas de redes e estratégias de processamento de dados, espera-se estabelecer referências que sirvam de base para pesquisas futuras. A publicação dos resultados em periódicos especializados e a disponibilização de ferramentas e modelos pré-treinados reforçam o compromisso com a disseminação aberta do conhecimento.

Sob uma perspectiva tecnológica, a utilização de *hardware* avançado, como GPUs de última geração, e a integração com plataformas abertas, como o *vailà*, possibilitam o desenvolvimento de ferramentas práticas e acessíveis. Essas inovações têm o potencial de revolucionar a forma como treinadores, pesquisadores e analistas interpretam e utilizam dados esportivos, facilitando a adoção de metodologias avançadas em diferentes contextos.

Adicionalmente, o impacto social e educacional do projeto não pode ser subestimado. Democratizar o acesso a tecnologias avançadas possibilita que clubes de base, escolas esportivas e profissionais de diversas áreas apliquem soluções tecnológicas sem a necessidade de recursos elevados ou conhecimento técnico aprofundado em inteligência artificial. A formação de parcerias entre universidades e instituições esportivas fortalece ainda mais a criação de um ambiente colaborativo e propício à inovação.

Por fim, o projeto posiciona o Brasil de forma competitiva no cenário global de inteligência artificial aplicada ao esporte. Ao incentivar o desenvolvimento de novas soluções tecnológicas, fomentar colaborações internacionais e apoiar o surgimento de *startups*, a iniciativa contribui para fortalecer a presença do país nesse campo emergente. Mais do que uma proposta técnica, o projeto reflete a essência do esporte, onde ciência, tecnologia e prática convergem para promover avanços significativos no desempenho e na disseminação do conhecimento.

1.3 Objetivos

1.3.1 Objetivos Específicos

Desenvolver e disponibilizar modelos de *deep learning* para rastreamento de jogadores e calibração de câmeras a partir de imagens aéreas capturadas por drones em perspectiva superior, com foco especial em categorias de base no futebol. Esses modelos serão integrados ao *framework vailá*, promovendo o acesso aberto, colaborativo e facilitado para pesquisadores e profissionais do esporte.

1.3.2 Objetivos Específicos

- Criar redes neurais para rastreamento de jogadores e detecção de linhas e pontos-chave do campo de futebol.
- Viabilizar a calibração de câmeras aéreas e a reconstrução geométrica do campo esportivo, utilizando dados extraídos de vídeos capturados por drones.
- Garantir alta precisão nos modelos por meio de técnicas de ajuste de dados (*data fitting*) e treinamento em GPUs de alto desempenho, como NVIDIA RTX 3090 e RTX 4090.
- Validar os modelos em cenários reais, aplicando-os a vídeos públicos ou capturados em condições controladas.
- Disponibilizar os modelos e ferramentas desenvolvidos na plataforma *vailá*, facilitando o uso de *deep learning* no esporte e incentivando novas investigações científicas e colaborações interdisciplinares.

1.4 Materiais e Métodos

O projeto foi planejado, seguindo etapas organizadas e integradas, para garantir a criação de modelos confiáveis de *deep learning* aplicados ao rastreamento de jogadores e calibração de câmeras em vídeos de futebol capturados por drones. É importante destacar que todos os equipamentos essenciais para a execução do projeto já foram adquiridos em projetos anteriores financiados pela FAPESP e CNPq, incluindo dois *workstations* de alto desempenho equipados com GPUs NVIDIA RTX 3090 e RTX 4090, um servidor de dados com capacidade de 80 TB de armazenamento para vídeos, e dois drones DJI (Mavic Mini 3 + Controle com tela + Kit Fly More). Os recursos da Bolsa PQ serão destinados à manutenção desses equipamentos e à possível aquisição de uma nova GPU recém-lançada, NVIDIA RTX 5090 no futuro.

1.4.1 Considerações Éticas

Com a finalidade de cumprir e garantir os preceitos da ética no desenvolvimento desta pesquisa, antes de iniciar a pesquisa, o presente projeto será submetido ao Comitê de Ética em pesquisa no Portal da Plataforma Brasil e só iniciará os procedimentos experimentais após aprovação. Todos os participantes deverão assinar o Termo de Assentimento Livre e sclarecido (TALE) e os pais ou maiores de idade, o termo de Consentimento Livre e Esclarecido (TCLE).

1.4.2 Coleta de Dados

A coleta de dados será realizada utilizando drones de alta qualidade, como o Mavic Mini 3, conhecidos por sua capacidade de capturar vídeos em resolução 4K a 60 Hz. As filmagens ocorrerão em campos de futebol oficiais, abrangendo categorias de base (sub-13, sub-15, sub-17 e sub-20). Os drones serão posicionados para capturar uma visão aérea completa (*top-down*), garantindo imagens nítidas das ações dos jogadores e das marcações do campo. Serão consideradas variáveis como condições de iluminação e uso de coletes coloridos para facilitar a identificação dos jogadores durante o processamento.

Mesmo com a vantagem de uma perspectiva superior para capturar o campo de futebol de maneira abrangente, desafios adicionais emergem durante o processo de coleta de dados. Problemas como sombras projetadas pelos jogadores e drones, como mostrado na Figura 1, podem dificultar o rastreamento preciso. Além disso, a presença de objetos não relacionados, como cones de treinamento ou bolas sobrantes no campo, pode introduzir confusão nos algoritmos de rastreamento e detecção, impactando diretamente a calibração das imagens da Figura 2. Esses aspectos reforçam a necessidade de algoritmos robustos capazes de lidar com tais interferências para garantir análises confiáveis.

Figure 1: Exemplo 1. Filmagem utilizando o drone DJI Mavic Air 2 em campo de futebol, ilustrando sombras projetadas como desafio para detecção.

Fonte: elaborado pelo autor (2025)

Figure 2: Exemplo 2. Filmagem utilizando o drone DJI Mavic Air 2 em campo de futebol, destacando a confusão visual causada por objetos adicionais no campo.

Fonte: elaborado pelo autor (2025)

Figure 3: Equipamentos adquiridos: (esquerda) dois drones DJI (Mavic Mini 3); (direita) *workstations* equipadas com GPUs NVIDIA RTX 3090 e RTX 4090 e Servidor de 80 TB.

Fonte: elaborado pelo autor (2025)

1.4.3 Rotulação e Pré-processamento

Os vídeos capturados serão rotulados manualmente com o auxílio de ferramentas como *LabelImg*, *DeepLabCut*, *napari* ou *vailá*. O processo incluirá a identificação de jogadores, linhas do campo, a bola e outros elementos relevantes. Para ampliar a qualidade e a robustez dos dados, serão aplicadas técnicas de *data augmentation*, como ajustes de brilho, contraste, rotação e adição

de ruído. Esses passos são fundamentais para assegurar que os modelos possam generalizar bem a novos contextos e condições [15].

1.4.4 Desenvolvimento e Treinamento dos Modelos

Para o desenvolvimento e treinamento dos modelos, utilizaremos arquiteturas reconhecidas por sua eficácia em tarefas de detecção e rastreamento, como as Redes Neurais Residuais (ResNet) nas variantes ResNet50, ResNet101 e ResNet152 [16], além da EfficientNet, conhecida por sua eficiência computacional [17]. Exploraremos também modelos baseados em *Transformers*, como o DETR (*Detection Transformer*), que demonstram capacidade avançada na detecção simultânea de múltiplos objetos [18, 19]. Adicionalmente, manteremos atenção às inovações emergentes na comunidade de aprendizado de máquina, explorando modelos disponibilizados na plataforma Hugging Face [20], que oferecem perspectivas de soluções atualizadas para tarefas de visão computacional.

O treinamento será conduzido em GPUs de alta capacidade de processamento (NVIDIA RTX 3090 e RTX 4090), utilizando os *frameworks* PyTorch ou TensorFlow, ambos com suporte à tecnologia CUDA e CuDNN da NVIDIA para aceleração computacional. Será dada atenção especial à otimização de hiperparâmetros, empregando validação cruzada e testes em dados externos, com o objetivo de garantir modelos precisos, robustos e capazes de generalizar bem a diferentes cenários e condições.

1.4.5 Validação

A validação dos modelos será realizada utilizando medidas manuais extraídas diretamente das imagens, consideradas como referência mais precisa para este projeto. Devido à impossibilidade de utilizar sistemas como o Vicon e OptiTrack em cenários de jogos reais de futebol — dado que esses sistemas requerem marcadores retrorreflexivos e técnicas de infravermelho incompatíveis com o ambiente aberto e dinâmico de um campo de jogo — a validação dependerá de análises humanas detalhadas.

Métricas como erro quadrático médio (RMSE) e erro médio absoluto (MAE) serão calculadas para avaliar a precisão do deslocamento e da velocidade dos jogadores detectados pelos modelos. Adicionalmente, serão realizados testes de confiabilidade entre diferentes observadores, a fim de assegurar a consistência dos resultados obtidos.

1.4.6 Integração com a Plataforma

Os modelos desenvolvidos serão integrados ao *vailá*, tornando-os acessíveis a pesquisadores e profissionais do esporte. Essa integração permitirá a análise automatizada de métricas posicionais e de desempenho, democratizando o acesso às ferramentas desenvolvidas, sem exigir conhecimentos avançados de computação.

1.4.7 Compartilhamento e Reprodutibilidade

Com o objetivo de fomentar a colaboração científica, todo o código, modelos treinados e *datasets* serão disponibilizados publicamente em repositórios como GitHub, Zenodo ou Hugging Face. A documentação detalhada acompanhará esses materiais, facilitando a reprodução dos experimentos e incentivando adaptações em outros contextos esportivos.
Com essas etapas, o projeto não apenas busca avanços técnicos, mas também se propõe a tornar suas soluções amplamente aplicáveis, beneficiando tanto a comunidade acadêmica quanto o setor esportivo.

1.5 Resultados Esperados

O projeto prevê a obtenção de resultados significativos que facilitem as análises esportivas no contexto do futebol com vídeos de drones, tendo como enfoque principial em categorias de base. Na sequência são pontuados os resultado esperado ao final deste projeto:

- **Modelos de Deep Learning de Alto Desempenho:** Desenvolvimento de redes neurais robustas para rastreamento de jogadores e calibração de câmeras com alta precisão, mesmo em condições desafiadoras, como iluminação variável e movimentação intensa. Modelos como ResNet e DETR, conhecidos por sua eficiência em visão computacional, servirão de base para alcançar precisão acima de 90% em tarefas de detecção [16, 18].

- **Base de Dados Anotada e Pública:** Criação de um conjunto de dados abrangente, incluindo vídeos capturados por drones em perspectiva superior, com anotações detalhadas sobre jogadores, linhas de campo e outros elementos. Este conjunto será disponibilizado publicamente em plataformas como Zenodo e Hugging Face, facilitando a replicabilidade e o avanço da pesquisa na área.

- **Integração com o *vailá*:** Implementação dos modelos desenvolvidos no *vailá*, permitindo fácil acesso e uso por pesquisadores e profissionais do esporte, simplificando análises e promovendo a democratização do uso de inteligência artificial [12].

- **Automação e Eficiência:** Melhoria nos processos de análise tática e identificação de eventos críticos, como impedimentos e formações estratégicas, por meio da automação baseada em inteligência artificial. Espera-se reduzir significativamente o tempo de análise manual, aumentando a eficiência e a precisão nas avaliações [14].
- **Acessibilidade e Reprodutibilidade:** Publicação de todos os códigos, modelos treinados e documentação técnica em repositórios de acesso aberto, como GitHub, Zenodo e Hugging Face. A iniciativa busca garantir a reprodutibilidade dos resultados e incentivar a adaptação dos métodos a outros contextos esportivos [14].

1.6 Cronograma

Table 1: Cronograma das atividades.

ATIVIDADE	2025				2026			
	1° Semestre		2° Semestre		1° Semestre		2° Semestre	
	1-3	4-6	7-9	10-12	1-3	4-6	7-9	10-12
Revisao de Literatura	X	X	X	X	X	X	X	X
Cumprimento dos Créditos de Mestrado	X	X	X	X				
Estudo Piloto		X	X					
Coleta de Dados			X	X				
Análise de Dados			X	X	X	X		
Apresentação em Congresso						X	X	
Defesa da Dissertação								X

References

[1] Athanasios Voulodimos, Nikolaos Doulamis, Anastasios Doulamis, and Eftychios Protopapadakis. Deep learning for computer vision: A brief review. *Computational intelligence and neuroscience*, 2018(1):7068349, 2018.

[2] Mahmoud Hassaballah and Ali Ismail Awad. *Deep learning in computer vision: principles and applications*. CRC Press, 2020.

[3] Junyi Chai, Hao Zeng, Anming Li, and Eric WT Ngai. Deep learning in computer vision: A critical review of emerging techniques and application scenarios. *Machine Learning with Applications*, 6:100134, 2021.

[4] Rodrigo Rico Bini, Felipe Arruda Moura, Paulo Roberto Pereira Santiago, Steffi Colyer, and Natalie Vanicek. Special issue themes: Markerless motion analysis in sport and exercise. *Journal of Sports Sciences*, 42(1):1–2, 2024. PMID: 38574060.

[5] Fábio Dalla Costa Figueiredo and Neucimar Jerônimo Leite. Calibração dinâmica de câmeras para rastreamento de jogadores de futebol durante o jogo. In *IX Congresso de Iniciação Científica da Unicamp*, 2000.

[6] Anthony Cioppa, Adrien Deliège, Floriane Magera, Silvio Giancola, Olivier Barnich, Bernard Ghanem, and Marc Van Droogenbroeck. Camera calibration and player localization in soccernet-v2 and investigation of their representations for action spotting. In *2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, pages 4532–4541, 2021.

[7] Jose Cerqueira Fernandes and Benjamin Kenwright. Identifying and extracting football features from real-world media sources using only synthetic training data. *arXiv preprint arXiv:2209.13254*, 2022.

[8] Luiz Henrique Palucci Vieira, Christopher Carling, Fabio Augusto Barbieri, Rodrigo Aquino, and P. R. P. Santiago. Match running performance in young soccer players: A systematic review. *Sports Medicine*, 49:289–318, 2019.

[9] R. L. M. Monteiro, C. C. A. Santos, P. Blauberger, D. Link, T. G. Russomanno, A. K. Tahara, A. G. Chinaglia, and P. R. P. Santiago. Enhancing soccer goalkeepers penalty dive kinematics with instructional video and laterality insights in field conditions. *Scientific Reports*, 14:10225–, 2024.

[10] B. L. S. Bedo, D. Catelli, M. Lamontagne, and P. R. P. Santiago. A custom musculoskeletal model for estimation of medial and lateral tibiofemoral contact forces during tasks with high knee and hip flexions. *Computer Methods in Biomechanics and Biomedical Engineering*, pages 1–6, 2020.

[11] João Gustavo Claudino, Daniel de Oliveira Capanema, and Paulo Roberto Pereira Santiago. *AIM in Sports Medicine*, pages 1819–1824. Springer International Publishing, Cham, 2022.

[12] Paulo Roberto Pereira Santiago, Abel Gonçalves Chinaglia, Kira Flanagan, Bruno LS Bedo, Ligia Yumi Mochida, Juan Aceros, Aline Bononi, and Guilherme Manna Cesar. vailá: Versatile anarcho integrated liberation Ánalysis in multimodal toolbox. *arXiv preprint arXiv:2410.07238*, 2024.

[13] Alexander Mathis, Pranav Mamidanna, Kevin M Cury, Taiga Abe, Venkatesh N Murthy, Mackenzie Weygandt Mathis, and Matthias Bethge. Deeplabcut: markerless pose estimation of user-defined body parts with deep learning. *Nature neuroscience*, 21(9):1281–1289, 2018.

[14] Jessy Lauer, Mu Zhou, Shaokai Ye, William Menegas, Steffen Schneider, Tanmay Nath, Mohammed Mostafizur Rahman, Valentina Di Santo, Daniel Soberanes, Guoping Feng, et al. Multi-animal pose estimation, identification and tracking with deeplabcut. *Nature Methods*, 19(4):496–504, 2022.

[15] Duc Haba. *Data Augmentation with Python: Enhance deep learning accuracy with data augmentation methods for image, text, audio, and tabular data*. Packt Publishing Ltd, 2023.

[16] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. *arXiv preprint arXiv:1512.03385*, 2015.

[17] Mingxing Tan and Quoc V Le. Efficientnet: Rethinking model scaling for convolutional neural networks. *arXiv preprint arXiv:1905.11946*, 2019.

[18] Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, and Sergey Zagoruyko. End-to-end object detection with transformers. *arXiv preprint arXiv:2005.12872*, 2020.

[19] Rui He, Zehua Fu, Qingjie Liu, Yunhong Wang, and Xunxun Chen. Dˆ 3: Duplicate detection decontaminator for multi-athlete tracking in sports videos. In *Proceedings of the Asian Conference on Computer Vision*, pages 142–159, 2022.

[20] Hugging Face. Object detection models, 2023.